Projet de Data Mining

Université de Montpellier

Master 2 MBFA – Parcours SIEF

Année universitaire 2025-2026

Analyse comparative des performances prédictives pour l'évaluation de la qualité du vin : modèles de machine learning classiques vs approche de deep learning par réseau de neurones

Réalisé par :
Amira Bensetita, Thierry Feugier

Sommaire

1. Introduction **1**
2. Analyse Exploratoire des Données **2**
2.1 Fusion des données et regroupement des classes 3
3. Prétraitement et Modélisation – Approche Machine Learning Classique **4**
3.1 Séparation des données : Train / Test 4
4. Modèles de Machine Learning Classiques **4**
4.1 Arbre de Décision 4
4.1.1 Grille de recherche et stratégie de validation 4
4.1.2 Entraînement retenu 6
4.2 Forêt Aléatoire (RandomForestClassifier) 7
4.2.1 Grille de recherche & validation 7
4.2.2 Entraînement retenu et résultats 7
4.3 K-Nearest Neighbors (KNN) 10
4.3.1 Grille de recherche & validation 10
4.3.2 Entraînement retenu 10
5. Choix du meilleur modèle Classique et limites **11**
6. Méthodologie – Approche Deep Learning (MLP) **12**
6.1 Architecture du réseau de neurones 12
6.2 Prétraitement et normalisation 13
6.3 Optimisation et dynamique d'apprentissage 13
6.4 Prise en compte du déséquilibre des classes 14
7. Résultats expérimentaux **15**
7.1 Performances des modèles classiques 15
7.2 Performances du MLP (sans et avec pondération des classes) 16
7.3 Comparaison globale des performances 17
8. Analyse comparative approfondie et interprétations des résultats **17**
9. Conclusion **18**

1. Introduction

L'évaluation de la qualité d'un produit constitue un enjeu central dans de nombreux secteurs industriels, et l'industrie viticole ne fait pas exception. La qualité d'un vin influence directement son positionnement commercial, sa valorisation sur le marché et la satisfaction des consommateurs. Traditionnellement, cette évaluation repose sur des analyses sensorielles réalisées par des experts, complétées par des mesures physico-chimiques objectives. Cependant, l'essor des méthodes de data science et d'apprentissage automatique ouvre la voie à des approches automatisées capables d'exploiter les caractéristiques mesurables du vin afin de prédire sa qualité. Dans ce contexte, le présent

projet s'intéresse à la prédiction de la qualité du vin à partir de variables physico-chimiques issues du célèbre dataset Wine Quality de l'UCI Machine Learning Repository. Ce jeu de données contient des observations relatives à des vins rouges et blancs, décrits par plusieurs indicateurs tels que l'acidité, le pH, la teneur en alcool, la concentration en dioxyde de soufre ou encore la densité. L'objectif est de construire un modèle capable de classifier automatiquement un vin en différentes catégories de qualité. Au-delà de la simple mise en œuvre d'un modèle prédictif, l'ambition de ce travail est comparative. Nous cherchons à répondre à la question suivante : **Les modèles de deep learning offrent-ils une amélioration significative des performances prédictives par rapport aux modèles de machine learning classiques pour une tâche de classification tabulaire telle que l'évaluation de la qualité du vin ?**

Pour répondre à cette problématique, deux grandes approches sont étudiées : D'une part, des modèles classiques de machine learning : Arbre de Décision, Random Forest et K-Nearest Neighbors (KNN). D'autre part, une approche de deep learning fondée sur un réseau de neurones de type Multi-Layer Perceptron (MLP). Les modèles sont entraînés et évalués dans un cadre méthodologique rigoureux comprenant une séparation des données en ensembles d'entraînement, de validation et de test, ainsi qu'une sélection d'hyperparamètres via validation croisée pour les modèles classiques. Les performances sont comparées principalement à l'aide de l'accuracy, tout en considérant également des métriques complémentaires telles que le F1-score et la balanced accuracy. Ce rapport s'organise comme suit. Nous présentons d'abord les données utilisées et la construction de la variable cible. Nous détaillons ensuite la méthodologie appliquée aux modèles classiques, puis celle adoptée pour l'approche deep learning. Les résultats expérimentaux sont ensuite comparés et analysés de manière critique, avant de conclure sur les limites de l'étude et les perspectives d'amélioration.

2. Analyse Exploratoire des Données

L'analyse exploratoire a été menée à partir du dataset UCI Wine Quality, qui regroupe deux bases distinctes : les vins rouges et les vins blancs. Chaque observation correspond à un vin décrit par 11 variables physico-chimiques (acidité fixe, acidité volatile, acide citrique, sucre résiduel, chlorures, SO_2 libre, SO_2 total, densité, pH, sulfates, alcool) et une variable cible quality (note sensorielle attribuée par des dégustateurs). Dans les données utilisées, la base vin rouge contient 1 599 observations et la base vin blanc 4 898 observations.

Avant toute modélisation, un contrôle de qualité des données a été réalisé. Il met en évidence l'absence de valeurs manquantes sur l'ensemble des variables (y compris la cible), ce qui permet de travailler sans imputation et garantit une cohérence statistique des analyses descriptives.

Sur le plan descriptif, les vins blancs présentent une plus forte dispersion sur certaines variables, ce qui est cohérent avec une diversité technologique plus marquée (notamment

sur les niveaux de sucre et de soufre). En moyenne, pour les vins blancs, l'acidité fixe s'établit à 6,85 (maximum 14,20), l'acidité volatile à 0,28 (maximum 1,10), l'acide citrique à 0,33 (maximum 1,66) et le sucre résiduel à 6,39 avec une valeur maximale très élevée (65,80), indiquant la présence de vins nettement plus sucrés que la médiane. Le SO_2 libre atteint en moyenne 35,30 (maximum 289) et le SO_2 total 138,36 (maximum 440). Enfin, l'alcool moyen des vins blancs est de 10,51 (maximum 14,20) et la qualité moyenne de 5,88 (maximum 9).

La distribution de la note quality est concentrée sur des valeurs intermédiaires, ce qui confirme que le problème est naturellement déséquilibré. Pour les vins blancs, les notes les plus fréquentes sont 6 (2 198) et 5 (1 457), tandis que les notes extrêmes restent rares (ex. 9 : 5 observations).

Ce constat justifie le regroupement ultérieur en classes (mauvaise / moyenne / bonne) afin d'obtenir un cadre de classification multiclasses plus stable.

En complément, la distribution par catégories (telle que construite dans l'EDA) met en évidence un déséquilibre structurel : pour les vins rouges, on compte 63 "Mauvaise", 1 319 "Moyenne" et 217 "Bonne".

Pour les vins blancs, on obtient 183 "Mauvaise", 3 655 "Moyenne" et 1 060 "Bonne".

Une fois fusionnés, cela implique une domination nette de la classe intermédiaire, ce qui aura un impact direct sur l'accuracy et rend indispensable l'analyse via des métriques par classe (rappel, F1-score, matrice de confusion).

Enfin, l'EDA met en évidence des relations cohérentes entre certaines variables et la qualité. Dans les deux bases, le degré d'alcool apparaît comme l'un des facteurs les plus associés à une meilleure qualité : les vins les mieux notés présentent en moyenne un alcool plus élevé. À l'inverse, l'acidité volatile est globalement liée négativement à la qualité, en particulier pour les vins rouges. Certaines variables comme les sulfates montrent une tendance légèrement positive, tandis que des variables comme le sucre résiduel, les chlorures ou le SO_2 total affichent un fort chevauchement entre catégories, ce qui suggère qu'aucune variable isolée ne suffit à discriminer parfaitement les classes. Ces constats renforcent l'intérêt de modèles multivariés capables de capter des interactions non linéaires.

2.1 Fusion des données et regroupement des classes

Les jeux de données des vins rouges et blancs ont été chargés séparément puis fusionnés, conduisant à un ensemble total de **6 497 observations** (1 599 rouges et 4 898 blancs).

Une variable binaire *wine_type* (0 = rouge, 1 = blanc) a été ajoutée afin d'intégrer le type de vin comme variable explicative. Après ajout de la variable, le DataFrame final comporte **14 colonnes**.

La variable cible *quality*, initialement comprise entre 3 et 8, a été transformée en trois catégories ordinales: 0 : Mauvaise (≤ 4), 1 : Moyenne (5–6), 2 : Bonne (≥ 7)

Ce regroupement vise à réduire la granularité du score initial, à limiter l'impact du déséquilibre entre les différentes classes de qualité et à stabiliser le problème en une classification multiclasse plus robuste. Toutefois, cette simplification entraîne une perte partielle de l'aspect strictement ordinal de la note d'origine, ce qui constitue un compromis méthodologique nécessaire pour faciliter la modélisation.

3. Prétraitement et Modélisation – Approche Machine Learning Classique

3.1 Séparation des données : Train / Test

Les données ont été séparées en deux ensembles :

- 80 % pour l'entraînement,
- 20 % pour le test,
  à l'aide de `train_test_split(..., stratify=y)`.

La stratification permet de conserver les proportions entre classes dans chaque ensemble, garantir la présence des classes minoritaires dans le test, et assurer une évaluation représentative et reproductible (*random_state = 42*).

4. Modèles de Machine Learning Classiques

Trois approches ont été retenues : Arbre de Décision, Random Forest et KNN. Elles couvrent trois familles différentes :

- un modèle interprétable et simple (Decision Tree),
- un modèle robuste et performant (Random Forest),
- un modèle basé sur les distances (KNN), sensible aux variations dans les données.

Chacun apporte une perspective différente sur la structure du problème.

4.1 Arbre de Décision

4.1.1 Grille de recherche et stratégie de validation

Afin d'optimiser les performances du classificateur Decision Tree, une procédure systématique de recherche d'hyperparamètres a été mise en place à l'aide de GridSearchCV.

Trois hyperparamètres majeurs influençant la complexité et la capacité de généralisation du modèle ont été étudiés :

- `max_depth` : profondeur maximale de l'arbre. Ce paramètre contrôle la complexité du modèle. Une profondeur élevée permet de capturer des relations complexes mais augmente le risque de sur-apprentissage.

- `min_samples_split` : nombre minimal d'échantillons requis pour diviser un nœud interne.Une valeur faible rend l'arbre plus flexible, tandis qu'une valeur plus élevée limite la croissance excessive de l'arbre.

- `min_samples_leaf` : nombre minimal d'échantillons requis dans une feuille. Ce paramètre agit comme un mécanisme de régularisation en empêchant la création de feuilles contenant très peu d'observations.

L'exploration combinatoire de ces paramètres a conduit à l'évaluation de 45 combinaisons distinctes.

Stratégie de validation croisée

Pour garantir une estimation robuste des performances, une validation croisée stratifiée à 5 folds a été utilisée via StratifiedKFold. La stratification permet de conserver la proportion des classes dans chaque sous-ensemble, ce qui est essentiel compte tenu du déséquilibre modéré de la variable cible.

Étant donné : 45 combinaisons d'hyperparamètres et 5 folds de validation, le processus a nécessité un total de 225 entraînements (45 × 5 fits). Cette approche réduit la variance de l'estimation et limite le risque que le modèle soit optimisé sur une partition particulière des données.

La procédure d'optimisation a conduit à la sélection des paramètres suivants: max_depth = 10, min_samples_split = 2, min_samples_leaf = 2

Interprétation des résultats

- Une profondeur maximale de 10 indique que le modèle bénéficie d'une certaine complexité tout en restant contrôlé.
- La valeur minimale de `min_samples_split` (2) suggère qu'autoriser des divisions précoces améliore la capacité du modèle à capturer les structures locales.
- La contrainte `min_samples_leaf = 2` agit comme un léger mécanisme de régularisation, limitant la création de feuilles trop spécifiques.

Globalement, ces paramètres traduisent un compromis entre flexibilité et généralisation, évitant un arbre trop profond susceptible de sur-apprendre, tout en conservant une capacité d'adaptation suffisante aux données.

4.1.2 Entraînement retenu

- Modèle final = arbre avec les meilleurs paramètres ci-dessus.
- Critère de sélection : accuracy moyenne CV maximale.
- Résultats (test, n=1 300)

Classe	Précision	Rappel	F1-score	Support
0 (*Mauvaise*)	0.14	0.06	0.08	49
1 (*Moyenne*)	0.84	0.91	0.88	995
2 (*Bonne*)	0.62	0.49	0.55	256
Global			**Acc. 0.7977**	1300

Le modèle **Decision Tree** obtient une accuracy globale de **79,77 %** sur un total de 1300 observations dans l'ensemble de test. À première vue, cette performance semble satisfaisante. Toutefois, cette métrique doit être analysée avec prudence, car la distribution des classes est déséquilibrée. En effet, la classe « Moyenne » représente à elle seule 995 observations sur 1300, soit environ 76 % des données. Ainsi, un modèle qui prédit majoritairement cette classe peut afficher une accuracy élevée tout en restant peu performant sur les classes minoritaires.

L'analyse détaillée par classe révèle des disparités importantes. Concernant la classe **« Mauvaise » (0)**, les résultats sont particulièrement faibles. Avec une précision de 0,14 et un rappel de seulement 0,06, le modèle parvient à identifier très peu de vins réellement classés comme mauvais. Le F1-score de 0,08 confirme cette difficulté. Cela signifie que la grande majorité des vins de faible qualité sont mal classés, généralement confondus avec la catégorie « Moyenne ». Cette faiblesse s'explique en partie par le faible nombre d'exemples disponibles pour cette classe (49 observations), mais également par la proximité des caractéristiques chimiques entre les vins « Mauvaise » et « Moyenne ».

En revanche, la classe **« Moyenne » (1)** présente d'excellentes performances. Avec une précision de 0,84 et un rappel de 0,91, le modèle identifie correctement la majorité des vins appartenant à cette catégorie. Le F1-score de 0,88 traduit un bon équilibre entre précision et rappel. Cette performance élevée est cohérente avec le fait que cette classe est largement majoritaire dans le dataset. Le modèle apprend principalement les caractéristiques associées à cette catégorie, ce qui améliore naturellement ses résultats sur celle-ci.

Pour la classe **« Bonne » (2)**, les performances sont intermédiaires. La précision atteint 0,62 tandis que le rappel est de 0,49, avec un F1-score de 0,55. Environ la moitié des vins réellement classés comme « Bons » sont correctement identifiés. Le reste est principalement confondu avec la classe « Moyenne ». Cette confusion est logique dans la mesure où les classes sont ordinales et proches les unes des autres. Les frontières entre «

Moyenne » et « Bonne » sont naturellement floues, ce qui rend la séparation plus complexe pour un arbre de décision.

Globalement, ces résultats montrent que l'arbre de décision présente un **biais en faveur de la classe majoritaire**. Bien que l'accuracy globale soit élevée, le modèle peine à détecter correctement les classes minoritaires, en particulier la classe « Mauvaise ». Cette situation illustre les limites de l'accuracy comme métrique unique d'évaluation dans un contexte déséquilibré. Une analyse plus fine des métriques par classe est indispensable pour juger de la qualité réelle du modèle.

En conclusion, le modèle Arbre de Décision offre une performance globale correcte mais inégalement répartie entre les classes. Il est particulièrement efficace pour prédire la qualité « Moyenne », acceptable pour la qualité « Bonne », mais très insuffisant pour la qualité « Mauvaise ». Ces résultats justifient l'exploration de modèles plus robustes, tels que les méthodes d'ensemble, afin d'améliorer la généralisation et la détection des classes minoritaires.

4.2 Forêt Aléatoire (RandomForestClassifier)

L'Agrégation de nombreux arbres réduit la variance , généralise mieux, capte les non-linéarités et interactions et est naturellement robuste au bruit et aux variables corrélées.

4.2.1 Grille de recherche & validation

- Paramètres explorés: `n_estimators`, `max_depth`, `min_samples_split`, `min_samples_leaf`.
- Validation : **5-folds stratifiés** (120 fits).
- **Meilleurs hyperparamètres trouvés:** `n_estimators = 200`, `max_depth = 20`, `min_samples_split = 2`, `min_samples_leaf = 1`.

4.2.2 Entraînement retenu et résultats

- Modèle final = **Random Forest** avec les **meilleurs paramètres** ci-dessus.
- Sélection faite par **accuracy CV** moyenne maximale.

Résultats (test, n=1 300) *(meilleur des modèles classiques)*

Classe	Précision	Rappel	F1-score	Support
0 (*Mauvaise*)	0.83	0.10	0.18	49

1 (*Moyenne*)	0.87	0.96	0.91	995
2 (*Bonne*)	0.79	0.60	0.68	256
Global			**Acc. 0.86**	1300

Les résultats du modèle Random Forest montrent des performances globalement élevées, avec une accuracy de **0.86** sur l'ensemble de test constitué de 1 300 observations. Cependant, une analyse détaillée par classe révèle des disparités importantes dans la capacité du modèle à distinguer correctement les différentes catégories de qualité du vin. La classe **Moyenne**, qui est largement majoritaire dans les données (995 échantillons), est prédite avec une grande précision (0.87) et un rappel quasi parfait (0.96). Cela signifie que le modèle identifie correctement la quasi-totalité de ces vins, ce qui contribue fortement au score global élevé.

En revanche, la classe **Bonne** obtient des résultats plus nuancés : un rappel de **0.60** indique que 60 % des bons vins sont détectés, tandis qu'un F1-score de **0.68** montre un équilibre raisonnable entre précision et rappel. Le modèle parvient donc à capter une partie des caractéristiques associées aux vins de haute qualité, mais il confond encore régulièrement ces vins avec ceux de qualité moyenne, probablement en raison du chevauchement important entre les deux profils physico-chimiques.

La situation est plus difficile pour la classe **Mauvaise**, très minoritaire (49 échantillons). Malgré une précision élevée (0.83), le rappel chute à **0.10**, ce qui signifie que le modèle détecte seulement 1 vin mauvais sur 10. Cette combinaison forte précision mais très faible rappel indique que le modèle « n'ose » presque jamais prédire cette classe. Cela reflète à la fois le déséquilibre des données et la similarité des caractéristiques avec la classe moyenne.

Globalement, ces métriques montrent que le modèle Random Forest est robuste et performant, mais que son efficacité dépend fortement de la représentativité des classes. Il excelle sur la classe majeure, se montre raisonnablement efficace sur la classe haute, mais rencontre des difficultés importantes sur la classe basse. Ces résultats mettent en évidence les limites classiques des modèles supervisés en présence de classes déséquilibrées et de frontières de décision floues dans l'espace des caractéristiques.

Contribution des Caractéristiques à la Prédiction de la Qualité du Vin

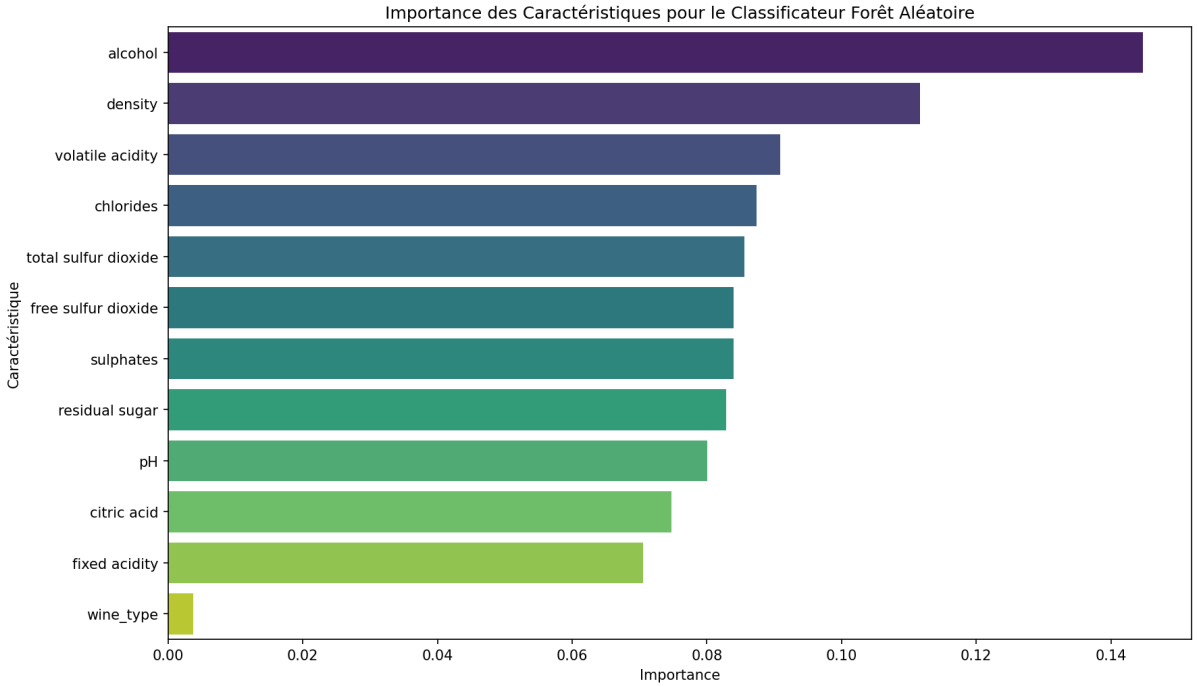

Le graphique représente l'importance moyenne des caractéristiques telle qu'estimée par le classificateur Random Forest, basé sur la réduction d'impureté (Mean Decrease in Gini). L'analyse montre que la teneur en alcool est le facteur le plus déterminant du modèle, contribuant à environ 14 % de la capacité discriminative totale. Cela indique que l'alcool joue un rôle majeur dans la séparation des classes de qualité, en raison de sa corrélation établie avec la perception sensorielle et les propriétés organoleptiques du vin.

La densité apparaît comme la deuxième variable la plus influente, ce qui est cohérent avec sa relation inverse avec la fermentation et la concentration en alcool. Des variables telles que l'acidité volatile, les chlorures et les différents niveaux de dioxyde de soufre (libre et total) jouent également un rôle significatif dans la décision, ce qui reflète leur impact sur la stabilité microbiologique et la détection de défauts aromatiques.

Les caractéristiques comme le pH, les sulfates, l'acide citrique ou le sucre résiduel ont un poids intermédiaire, ce qui suggère qu'elles contribuent à affiner les frontières de décision sans être les déterminants principaux. Enfin, la variable wine_type est presque négligeable dans le modèle, ce qui indique que, une fois les paramètres physico-chimiques intégrés, la distinction rouge/blanc n'apporte pas d'information discriminante supplémentaire.

En résumé, la Random Forest confirme que les variables liées à la composition chimique directement perceptible (alcool, acidité, densité, sulfates) sont les plus pertinentes pour prédire la qualité du vin, et que l'origine « vin rouge vs vin blanc » n'est pas un facteur discriminant une fois ces mesures prises en compte.

4.3 K-Nearest Neighbors (KNN)

Ce modèle est basé sur la similarité locale, c'est bon comparatif non paramétrique. Il nécessite une standardisation (sinon biais par l'échelle des variables).

4.3.1 Grille de recherche & validation

- Paramètres explorés : `n_neighbors`, `weights`, p (1=Manhattan, 2=Euclidienne).
- Validation : 5-folds stratifiés (80 fits).
- Meilleurs hyperparamètres trouvés : `n_neighbors = 9`, `p = 2`, `weights = 'distance'`.

4.3.2 Entraînement retenu

- Pipeline StandardScaler + KNN avec meilleurs paramètres.
- Sélection par accuracy CV moyenne.

Résultats (test, n=1 300)

Classe	Précision	Rappel	F1-score	Support
0 (*Mauvaise*)	0.88	0.14	0.25	49
1 (*Moyenne*)	0.87	0.92	0.89	995
2 (*Bonne*)	0.66	0.62	0.64	256
Global			**Acc. 0.83**	1300

Les résultats du modèle K-Nearest Neighbors montrent une performance globale correcte, avec une accuracy de **0.83** sur les 1 300 échantillons du jeu de test. Toutefois, comme pour les autres modèles, une analyse par classe met en évidence des différences notables selon la catégorie de qualité du vin. La classe **Moyenne**, largement majoritaire (995 observations), bénéficie des meilleures performances, avec une précision de **0.87**, un rappel de **0.92** et un F1-score de **0.89**. Le modèle parvient donc à identifier la plupart des vins de qualité moyenne, ce qui contribue fortement à son score global.

La classe **Bonne** présente des performances intermédiaires : un rappel de **0.62** signifie que le modèle récupère plus de la moitié des vins de bonne qualité, tandis qu'un F1-score de **0.64** indique un compromis raisonnable entre précision et rappel. Cela montre que KNN parvient à capturer des similarités dans l'espace des caractéristiques pour distinguer les bons vins, même si une proportion non négligeable est encore reclassée en qualité moyenne.

En revanche, la classe **Mauvaise**, très minoritaire (49 vins), demeure difficile à détecter. Malgré une précision élevée (**0.88**), le rappel reste faible (**0.14**), ce qui signifie que peu de vins réellement mauvais sont identifiés. Le modèle hésite donc à prédire cette classe, probablement à cause d'un **chevauchement important dans les caractéristiques** entre les vins mauvais et moyens, mais aussi du fait que KNN est très sensible au déséquilibre des classes et à la proximité structurelle des données.

Globalement, ces résultats montrent que KNN est performant sur les classes majoritaires et raisonnablement efficace sur les bonnes qualités, mais qu'il présente des limites importantes pour distinguer la classe de mauvaise qualité. Ce comportement reflète à la fois la nature du problème, marqué par un fort déséquilibre et une proximité chimique entre les catégories, et les limites intrinsèques de ce modèle basé sur les distances.

5. Choix du meilleur modèle Classique et limites

Le modèle Random Forest apparaît comme le plus performant parmi ceux testés, notamment en comparaison avec KNN et Decision Tree. Plusieurs raisons expliquent cet avantage. Contrairement à un arbre de décision unique, Random Forest repose sur l'agrégation de nombreux arbres construits à partir de sous-échantillons aléatoires des données et des variables. Cette approche réduit fortement la variance et limite ainsi le surapprentissage. De plus, les relations entre les variables physico-chimiques du vin sont souvent non linéaires et complexes. Random Forest possède la capacité de modéliser efficacement ces interactions sans nécessiter d'hypothèses strictes sur la structure des données. Sa robustesse face au bruit constitue également un atout : certaines variables peuvent être redondantes ou peu informatives, mais la méthode de bagging réduit leur influence. À l'inverse, KNN peut être perturbé par la proximité et le chevauchement des classes, tandis qu'un arbre de décision isolé tend à surapprendre. Ainsi, Random Forest offre globalement un meilleur compromis biais-variance.

Plusieurs limites inhérentes au dataset doivent également être mises en lumière. Tout d'abord, les classes de qualité du vin présentent un déséquilibre notable : les notes intermédiaires (notamment 5 et 6) sont largement majoritaires, alors que les notes très basses ou très élevées demeurent rares. Cette distribution rend la classification plus complexe et influence directement les métriques telles que l'accuracy. Ensuite, la variable cible elle-même est subjective. La qualité du vin est évaluée par des dégustateurs dont les appréciations peuvent varier selon le contexte, l'expérience ou des critères personnels. Le modèle cherche ainsi à prédire une perception humaine plutôt qu'une mesure objective. Enfin, les variables disponibles se limitent à des caractéristiques physico-chimiques, alors que des facteurs clés comme le terroir, le cépage, le procédé de vinification ou encore l'âge du vin influencent fortement la qualité mais n'apparaissent pas dans les données.

Le caractère multiclasse du problème constitue également une difficulté importante. Les niveaux de qualité suivent une échelle ordinale, mais le modèle de classification traite ces classes comme indépendantes, sans tenir compte de l'ordre naturel entre les valeurs. Les frontières entre classes voisines, comme 5 et 6, sont très floues, ce qui engendre de nombreuses confusions. Par ailleurs, une erreur de prédiction proche (prédire 6 au lieu de 5) est pénalisée autant qu'une erreur éloignée (6 au lieu de 9), alors que cela ne reflète pas la réalité de la tâche. Cette inadéquation méthodologique suggère qu'une approche de régression ou un modèle explicitement conçu pour les données ordinales pourrait être plus pertinent.

Gestion du Déséquilibre des Classes avec SMOTE

Une tentative d'équilibrage des classes a été réalisée à l'aide de SMOTE (Synthetic Minority Over-sampling Technique). Toutefois, l'intégration de cette méthode a entraîné une diminution des performances globales des modèles, ce qui a conduit à son retrait dans la version finale. Plusieurs raisons permettent d'expliquer ce résultat.

Tout d'abord, les classes de qualité présentent un chevauchement naturel important en raison de leur caractère ordinal et de leur proximité (par exemple, les notes 5 et 6). Étant donné que SMOTE génère des observations synthétiques par interpolation entre des instances minoritaires, il peut produire des points ambigus dans un espace où les frontières entre classes sont déjà floues. Dans ce contexte, l'ajout de données artificielles peut accentuer la confusion plutôt que clarifier la séparation.

Ensuite, le déséquilibre observé dans le dataset reste modéré. Même si certaines classes sont minoritaires, la distribution n'atteint pas un niveau critique nécessitant un rééquilibrage intensif. De plus, les modèles comme Random Forest sont naturellement robustes face à des déséquilibres modérés, ce qui limite l'intérêt d'un sur-échantillonnage synthétique. L'introduction de nouvelles observations peut alors ajouter du bruit inutilement, sans réel bénéfice.

Par ailleurs, les classes rares, notamment celles correspondant aux notes très élevées ou très faibles, comportent peu d'observations réelles. Générer des points synthétiques à partir de si peu de données augmente le risque d'amplifier des valeurs atypiques ou bruitées, ce qui nuit à la capacité de généralisation du modèle.

Enfin, l'impact sur l'accuracy globale s'est révélé défavorable. Bien que l'équilibrage ait pu améliorer légèrement les performances sur certaines classes peu représentées, il a simultanément dégradé la précision sur les classes majoritaires. Au final, cette redistribution artificielle a conduit à une baisse de la performance globale, rendant l'utilisation de SMOTE contre-productive dans ce cas précis.

6. Méthodologie – Approche Deep Learning (MLP)

6.1 Architecture du réseau de neurones

Afin d'évaluer la pertinence d'une approche Deep Learning sur ce problème de classification multiclasses, un réseau de neurones de type **Multi-Layer Perceptron (MLP)** a été mis en œuvre. Contrairement aux modèles arborescents, qui segmentent l'espace des variables à

travers des règles successives, un MLP apprend une transformation non linéaire des variables d'entrée via des couches entièrement connectées, permettant de modéliser des interactions complexes entre caractéristiques.

L'architecture retenue comporte une couche d'entrée correspondant au nombre total de variables explicatives, une ou plusieurs couches cachées activées par une fonction non linéaire, puis une couche de sortie à trois neurones correspondant aux trois classes de `quality_grouped` (0 : Mauvaise, 1 : Moyenne, 2 : Bonne). Les sorties sont interprétées comme des logits, transformés en probabilités via une fonction softmax intégrée à la fonction de perte.

Ce choix est adapté à la structure du dataset : les variables sont exclusivement numériques et indépendantes les unes des autres au sens structurel (absence de dépendances temporelles ou spatiales). L'objectif du réseau est donc d'apprendre une frontière de décision non linéaire dans un espace de dimension modérée.

Une initialisation adaptée des poids a été utilisée afin de stabiliser les activations dès le début de l'apprentissage et d'éviter des gradients trop faibles ou trop élevés. Cette précaution contribue à une convergence plus régulière du modèle.

6.2 Prétraitement et normalisation

L'optimisation d'un réseau de neurones repose sur la descente de gradient. Dans ce cadre, l'échelle des variables influence directement la magnitude des gradients et la stabilité de l'apprentissage. Les variables physico-chimiques du dataset présentent des ordres de grandeur différents (par exemple, la concentration en dioxyde de soufre peut être bien plus élevée que la valeur du pH), ce qui rend la normalisation indispensable.

Les variables explicatives ont été standardisées à l'aide d'un **StandardScaler**, chaque variable étant transformée en une distribution centrée réduite. Le scaler a été ajusté exclusivement sur l'ensemble d'entraînement, puis appliqué aux ensembles de validation et de test. Cette procédure garantit que les données de test ne contribuent pas indirectement à l'apprentissage, évitant toute fuite d'information.

Contrairement aux modèles arborescents, relativement insensibles à l'échelle des variables, le MLP dépend fortement de cette étape pour assurer une optimisation stable et efficace.

6.3 Optimisation et dynamique d'apprentissage

Le problème étant formulé comme une classification multiclasses, la fonction de perte utilisée est l'**entropie croisée**. Cette fonction compare les probabilités prédites aux étiquettes réelles et pénalise fortement les prédictions incorrectes effectuées avec une grande confiance.

L'optimisation des paramètres est réalisée à l'aide de l'algorithme **Adam**, choisi pour sa capacité à adapter dynamiquement le taux d'apprentissage de chaque paramètre. Adam combine des estimations du premier et du second moment des gradients, ce qui facilite la convergence et réduit la sensibilité au choix initial du learning rate.

L'apprentissage est suivi à l'aide d'un ensemble de validation distinct. Les courbes d'entraînement montrent une diminution progressive de la loss sur l'ensemble d'entraînement, accompagnée d'une stabilisation sur l'ensemble de validation. Dans la configuration sans pondération des classes, l'accuracy de validation se stabilise autour de 0.79–0.80, tandis que l'accuracy d'entraînement progresse légèrement au-delà de 0.82, indiquant un léger écart mais sans divergence excessive.

Un mécanisme d'**early stopping** est mis en place : l'entraînement est interrompu lorsque la performance sur la validation cesse de s'améliorer. Dans la configuration avec pondération des classes, l'arrêt anticipé intervient à l'epoch 137, ce qui confirme que le modèle converge plus lentement lorsque les poids modifient la dynamique de la perte. L'early stopping permet de conserver l'état du modèle présentant la meilleure performance hors échantillon, limitant ainsi le risque de sur-apprentissage.

6.4 Prise en compte du déséquilibre des classes

L'analyse exploratoire du dataset met en évidence une forte prédominance de la classe intermédiaire (qualité moyenne). Dans un tel contexte, un modèle entraîné sans ajustement particulier tend naturellement à privilégier cette classe afin de maximiser l'accuracy globale.

Cette tendance apparaît clairement dans la configuration standard du MLP (sans pondération). Sur l'ensemble de test, l'accuracy atteint environ **0.81**, mais l'analyse détaillée révèle un déséquilibre marqué dans la reconnaissance des classes. La classe « Moyenne » est prédite avec une grande précision (recall ≈ 0.95), tandis que la classe « Mauvaise » est très peu détectée (recall ≈ 0.12) et la classe « Bonne » seulement partiellement reconnue (recall ≈ 0.40). La **balanced accuracy** est ainsi limitée à environ **0.49**, révélant une performance très inégale entre catégories. Afin de corriger ce biais, une pondération des classes a été introduite dans la fonction de perte. Les poids utilisés sont inversement proportionnels aux fréquences des classes, ce qui augmente le coût des erreurs commises sur les catégories minoritaires.

L'impact de cette modification est significatif. Avec pondération, l'accuracy globale diminue à environ **0.62**, mais la reconnaissance des classes minoritaires progresse fortement : le recall de la classe « Mauvaise » atteint environ **0.65**, et celui de la classe « Bonne » environ **0.81**. La **balanced accuracy** s'élève à **0.6765**, indiquant une distribution des performances beaucoup plus homogène entre classes.

Ce contraste met en évidence un arbitrage clair : la maximisation de l'accuracy globale favorise la classe majoritaire, tandis que la pondération améliore l'équité de la classification au prix d'une baisse de performance moyenne. Selon l'objectif applicatif — optimisation globale ou meilleure détection des classes extrêmes — le choix entre ces deux configurations peut varier.

7. Résultats expérimentaux

7.1 Performances des modèles classiques

Les modèles classiques ont été évalués sur l'ensemble de test, strictement séparé des données utilisées pour l'entraînement et la validation. Les performances reportées constituent donc une estimation hors échantillon de la capacité de généralisation.

Après optimisation des hyperparamètres par validation croisée, les accuracies obtenues sur l'ensemble de test sont les suivantes :

- **Arbre de Décision optimisé** : 0.7977
- **K-Nearest Neighbors optimisé** : 0.8292
- **Random Forest optimisé** : 0.8554

Le Random Forest apparaît comme le modèle le plus performant en termes d'accuracy globale. Cette supériorité s'explique par son caractère ensembliste : l'agrégation de plusieurs arbres réduit la variance et permet de capturer efficacement des interactions non linéaires entre variables.

L'analyse des rapports de classification apporte toutefois un éclairage plus nuancé. Comme pour le MLP sans pondération, la classe majoritaire (« Moyenne ») est prédite avec une très grande précision (recall ≈ 0.96 pour le Random Forest), tandis que la classe « Mauvaise » reste difficile à détecter (recall ≈ 0.10). La macro moyenne des F1-scores pour le Random Forest s'établit autour de 0.59, révélant un déséquilibre dans la qualité des prédictions selon les classes.

Le KNN obtient une performance intermédiaire (accuracy ≈ 0.83), avec un comportement similaire : bonne reconnaissance de la classe majoritaire et difficultés sur la classe minoritaire. L'Arbre de Décision seul présente la performance la plus faible et une sensibilité plus marquée aux erreurs sur les classes rares.

Le modèle retenu comme référence classique est donc le **Random Forest**, en raison de sa meilleure accuracy globale et de sa stabilité.

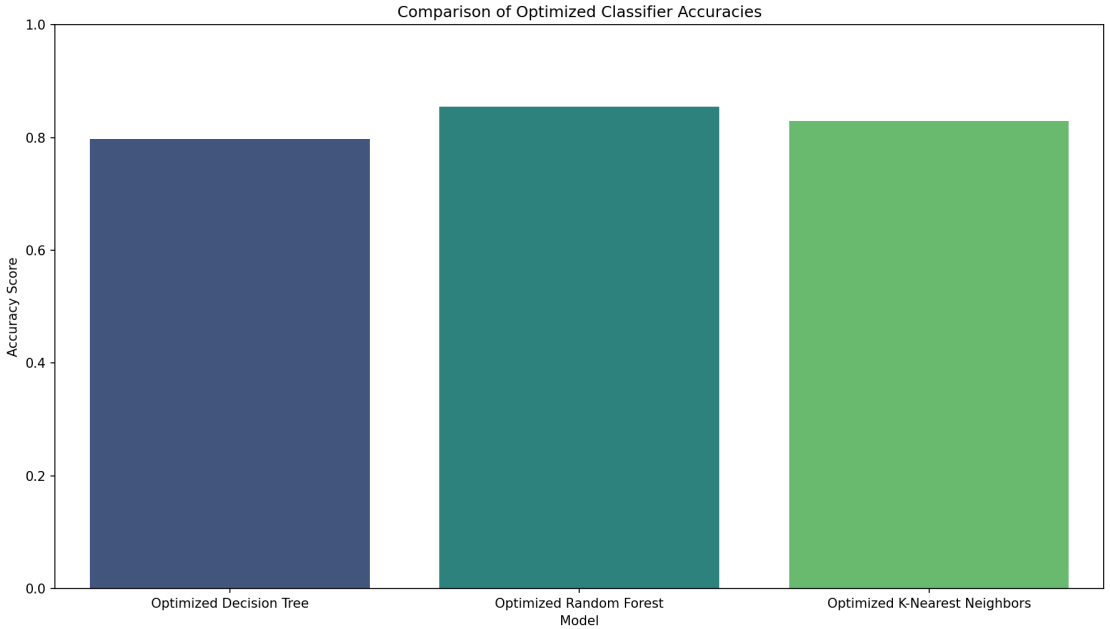

7.2 Performances du MLP (sans et avec pondération des classes)

L'évaluation du modèle Deep Learning repose sur la même séparation stricte des données. Deux configurations ont été comparées :

- MLP sans pondération des classes (nocw)
- MLP avec pondération des classes (cw)

Évolution de l'apprentissage

Dans la configuration sans pondération, la loss d'entraînement diminue régulièrement tandis que l'accuracy de validation se stabilise autour de 0.79–0.80. L'écart entre train et validation reste modéré (train_acc ≈ 0.82 en fin d'entraînement), ce qui suggère un sur-apprentissage limité. L'early stopping intervient lorsque la performance de validation cesse de progresser, garantissant une sélection du meilleur état du modèle.

Dans la configuration avec pondération, la dynamique d'apprentissage est différente. L'accuracy de validation est plus faible (autour de 0.63), mais l'apprentissage se poursuit plus longtemps avant déclenchement de l'early stopping (epoch 137), signe que la fonction de perte pondérée modifie la trajectoire d'optimisation.

Les résultats obtenus sur l'ensemble de test sont les suivants :

MLP sans class weights (nocw)

- Accuracy : 0.8077
- Macro-F1 : 0.5315
- Balanced Accuracy : 0.4892

MLP avec class weights (cw)

- Accuracy : 0.6185
- Macro-F1 : 0.5128
- Balanced Accuracy : 0.6765

L'analyse détaillée révèle des comportements très contrastés :

Sans pondération, le modèle atteint une accuracy comparable à celle du KNN, mais cette performance est largement portée par la classe majoritaire. La classe « Moyenne » est prédite avec un recall proche de 0.95, tandis que la classe « Mauvaise » est très peu détectée (recall ≈ 0.12). La balanced accuracy faible (≈ 0.49) confirme une performance très inégale entre classes.

Avec pondération, l'accuracy globale diminue fortement (≈ 0.62), mais la reconnaissance des classes minoritaires progresse de manière significative. Le recall de la classe « Mauvaise » atteint environ 0.65 et celui de la classe « Bonne » environ 0.81. La balanced accuracy augmente ainsi à 0.6765, indiquant une meilleure homogénéité des performances entre catégories.

7.3 Comparaison globale des performances

La comparaison finale met en évidence les accuracies suivantes :

- **Random Forest (classique)** : 0.8554
- **MLP (nocw)** : 0.8077
- **MLP (cw)** : 0.6185

Le Random Forest reste le modèle le plus performant en termes d'accuracy globale. Le MLP sans pondération se positionne en seconde place, tandis que la version pondérée sacrifie l'accuracy au profit d'une meilleure reconnaissance des classes minoritaires. Cette comparaison montre que, sur des données tabulaires de taille modérée, les modèles ensemblistes demeurent particulièrement compétitifs. Le Deep Learning ne surpasse pas les méthodes classiques en accuracy brute, mais il offre une flexibilité supplémentaire dans la gestion du déséquilibre des classes. L'interprétation des résultats dépend donc de l'objectif recherché : maximiser la performance globale ou équilibrer la qualité de prédiction entre catégories.

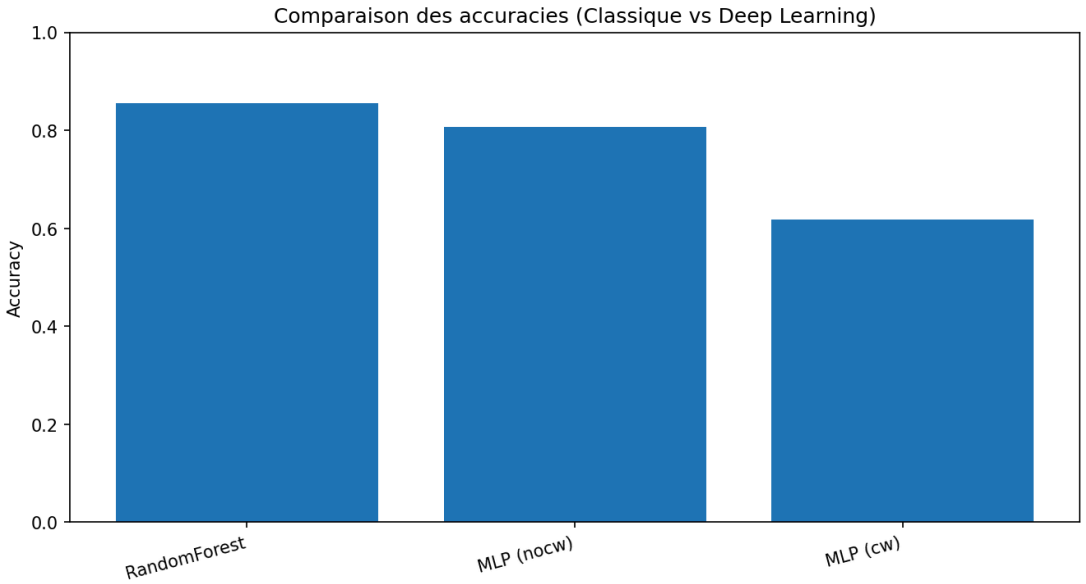

8. Analyse comparative approfondie et interprétations des résultats

Les résultats obtenus mettent en évidence un point important : selon la métrique retenue, la conclusion sur le "meilleur" modèle peut changer. En termes d'accuracy pure, le **Random Forest** est le modèle le plus performant, avec une accuracy de **0.8554** sur l'ensemble de test. Cette performance confirme l'efficacité des méthodes ensemblistes sur des données

tabulaires numériques, en particulier lorsqu'elles contiennent des relations non linéaires et des interactions entre variables. Les forêts aléatoires bénéficient d'un bon compromis biais–variance et sont souvent très compétitives sans nécessiter une optimisation aussi délicate que le Deep Learning.

Du côté Deep Learning, le MLP entraîne deux comportements très différents selon la manière dont le déséquilibre des classes est pris en compte. Sans pondération (*nocw*), le modèle obtient une accuracy de **0.8077**, ce qui reste correct mais demeure inférieur au Random Forest. Surtout, cette performance globale masque une faiblesse structurelle : le modèle se comporte comme un classifieur fortement attiré par la classe majoritaire. Sur l'ensemble de test, la classe "Mauvaise" est très peu reconnue (recall ≈ 0.12), et la classe "Bonne" est imparfaitement détectée (recall ≈ 0.40), alors que la classe "Moyenne" est prédite avec une grande facilité. Autrement dit, l'accuracy est portée principalement par la capacité du modèle à identifier la classe dominante.

À l'inverse, l'introduction de pondérations de classes (*cw*) modifie profondément l'équilibre des prédictions. L'accuracy globale baisse à **0.6185**, mais la reconnaissance des classes extrêmes progresse nettement : la classe "Mauvaise" atteint un recall d'environ **0.65**, et la classe "Bonne" un recall d'environ **0.81**. Cette amélioration se reflète directement dans la **balanced accuracy**, qui passe d'environ **0.489** (nocw) à **0.6765** (cw). Le modèle devient donc plus équitable entre classes, au sens où il ne sacrifie plus systématiquement les catégories minoritaires.

Cette différence entre *nocw* et *cw* illustre bien que l'accuracy seule peut être insuffisante dans un contexte de classes déséquilibrées. Si l'objectif applicatif est de mieux identifier les vins de faible ou bonne qualité (classes rares mais potentiellement plus "utiles" à détecter), la pondération peut représenter un compromis pertinent, même si elle pénalise l'accuracy globale.

9. Conclusion

L'étude comparative menée dans ce projet montre clairement que le **Random Forest constitue le modèle le plus performant sur ce jeu de données**, tant en termes d'accuracy globale que de stabilité des résultats entre classes. Avec une accuracy de 0.8554 sur l'ensemble de test, il surpasse l'Arbre de Décision, le KNN ainsi que les deux configurations du MLP. Ce résultat s'explique par l'adéquation particulièrement forte entre la structure du problème et les propriétés du modèle ensembliste.

Les données étudiées sont tabulaires, de dimension modérée, et comportent des relations non linéaires plausibles entre variables (alcool, densité, acidité volatile, sulfates, dioxyde de soufre, etc.) et qualité du vin. Le Random Forest est particulièrement efficace dans ce contexte, car il partitionne l'espace des variables de manière flexible et capture naturellement des interactions complexes sans nécessiter de transformations avancées. L'agrégation de multiples arbres réduit la variance et limite le surapprentissage, offrant ainsi un excellent compromis biais-variance.

Le comportement du MLP sans pondération des classes confirme quant à lui une limite classique des réseaux de neurones en contexte déséquilibré. En minimisant une fonction de perte moyenne, le modèle tend à privilégier la classe majoritaire afin d'optimiser mécaniquement l'accuracy. Cette stratégie conduit à une performance globale correcte (accuracy ≈ 0.81), mais masque une généralisation très inégale entre classes, comme l'indique la balanced accuracy nettement plus faible. Autrement dit, le modèle apprend efficacement la classe dominante, mais peine à détecter correctement les classes minoritaires.

L'introduction des class weights modifie la dynamique d'apprentissage. En pénalisant davantage les erreurs sur les classes sous-représentées, le modèle adopte une stratégie plus équilibrée. Toutefois, ce rééquilibrage s'accompagne d'une baisse significative de l'accuracy globale (≈ 0.62). Cette diminution ne traduit pas un échec méthodologique, mais un changement d'objectif implicite : il ne s'agit plus de maximiser le nombre total de prédictions correctes, mais de réduire le biais de classification entre classes. Le modèle accepte davantage d'erreurs sur la classe majoritaire afin d'améliorer la reconnaissance des catégories minoritaires.

Ces résultats soulignent une conclusion plus générale : sur des données tabulaires de taille intermédiaire, le Deep Learning n'offre pas nécessairement un avantage automatique par rapport aux méthodes classiques. Sa performance dépend fortement du réglage des hyperparamètres, des choix de régularisation et de la gestion du déséquilibre. À l'inverse, les modèles ensemblistes comme le Random Forest restent extrêmement compétitifs, robustes et simples à exploiter.

En définitive, dans le cadre de ce problème de classification de la qualité des vins, le Random Forest apparaît comme la solution la plus pertinente si l'objectif est d'optimiser l'accuracy globale. Le MLP constitue néanmoins une alternative intéressante pour explorer des stratégies plus fines de traitement du déséquilibre et pour analyser les compromis entre performance globale et équité entre classes. Ce travail met ainsi en évidence l'importance d'adapter le choix du modèle non seulement à la nature des données, mais également aux objectifs d'évaluation retenus.